Reconstrucción y detección 3d en interiores

Carlos Andrés Galán Pérez

Visión computacional *Universidad del Rosario*

Abstract Este proyecto presenta un pipeline capaz de reconstruir espacios interiores y reconocer sus elementos a partir de un simple video. La propuesta combina reconstrucción 3D y análisis semántico para obtener una escena en forma de nube de puntos enriquecida con información sobre objetos y superficies estructurales. El resultado es una representación tridimensional clara, intuitiva y útil para comprender la geometría y el contenido del entorno sin necesidad de re-entrenamiento adicional ni hardware especializado.

I. Introducción

La reconstrucción 3D de escenas interiores a partir de video ha avanzado significativamente gracias a técnicas modernas de fotogrametría y SLAM, permitiendo reconstruir la escena en forma de nubes de puntos que capturan la estructura visual del entorno. Pero el valor actual de estas tecnologías no termina en la obtención de puntos: hoy es posible interpretar qué representan esos puntos, detectar objetos, reconocer superficies y entender la estructura arquitectónica del espacio. Así, ya no se trata solo de reconstruir un escenario, sino también de comprender lo que existe dentro de él, fusionando la reconstrucción de puntos con la interpretación semántica a partir de un video convencional.

En este proyecto se implementa un pipeline completo que integra la reconstrucción inicial mediante **SLAM3R**, seguida de un preprocesamiento obligatorio basado en PCA para normalizar y alinear la nube de puntos. Posteriormente, la nube refinada es procesada con **SpatialLM**, un modelo multimodal capaz de razonar sobre nubes de puntos 3D para detectar objetos y elementos estructurales como paredes, puertas y ventanas. Las detecciones de muros se utilizan para colorear las superficies, permitiendo visualizar intuitivamente la geometría del lugar, de forma similar a la lectura de planos arquitectónicos. Esta integración convierte un video común en una representación 3D rica, tanto en estructura como en significado.

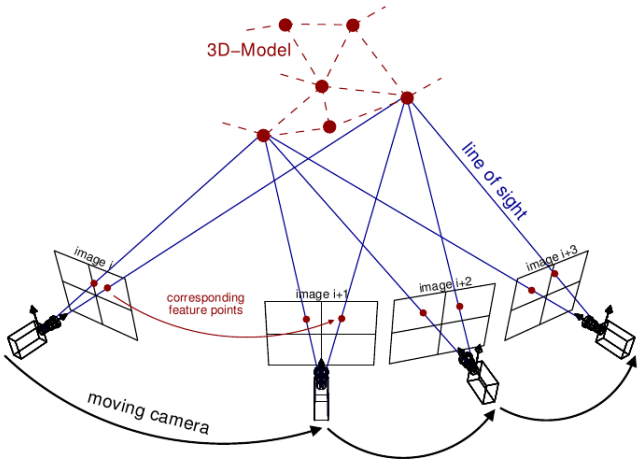
II. Marco teórico

1. Fotogrametría y Reconstrucción 3D:

La fotogrametría permite obtener reconstrucciones tridimensionales a partir de imágenes o video, estimando la estructura del entorno mediante correspondencias visuales y triangulación. En escenarios interiores, estas técnicas generan nubes de puntos densas que representan la escena reconstruida desde el movimiento de cámara. Estas nubes suelen poseer escala y orientación arbitrarias, por lo que requieren una etapa de alineación antes de recibir análisis semántico.

2. SLAM3R

Un sistema moderno de reconstrucción basado en SLAM que estima simultáneamente la trayectoria de la cámara y genera una nube de puntos del entorno. A partir de un video, produce una reconstrucción 3D densa pero sin escala métrica ni orientación fija, lo que hace necesario un preprocesamiento adicional para permitir su uso con modelos de interpretación semántica.

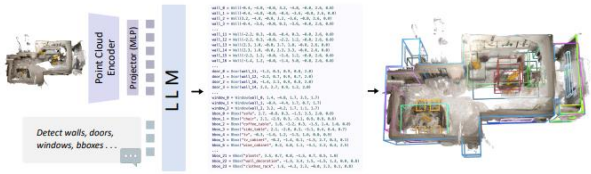


3. Alineación y Normalización PCA

El módulo de preprocesamiento empleado utiliza PCA (Análisis de Componentes Principales) para centrar la nube, alinear su eje vertical con el eje Z y ajustarla a una escala aproximada basada en la altura típica de una habitación. Además, corrige la posición del piso fijándolo en Z = 0. Este paso es obligatorio para generar una nube compatible con SpatialLM.

4. SpatialLM

Un modelo de lenguaje multimodal capaz de razonar sobre nubes de puntos 3D. Utiliza un codificador geométrico para extraer representaciones espaciales y genera un prompt textual que se pasa a un LLM (Llama-1B o Qwen-0.5B). El LLM produce descripciones y detecciones de objetos y superficies, las cuales se refinan con un perceptrón multicapa antes de generar un archivo .txt con las predicciones finales.



5. Reconstrucción de Superficies

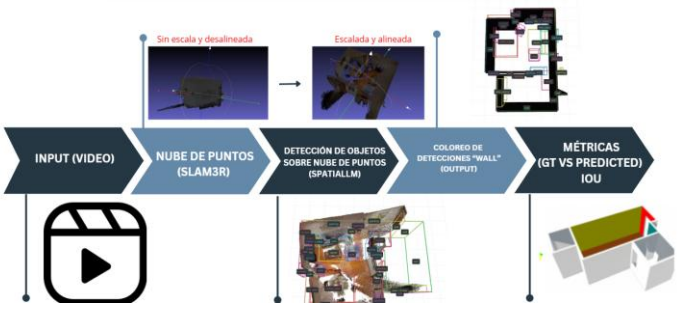
Mediante el archivo de predicciones generado por SpatialLM, las paredes se reconstruyen como paneles 3D usando Open3D. Cada línea Wall(x1,y1,z1,x2,y2,z2,height,yaw) se transforma en una malla orientada que representa las superficies estructurales del espacio, aproximando la idea de un plano arquitectónico del interior.

6. Métricas IoU y F1@IoU0.25

El rendimiento de SpatialLM se evalúa con IoU, que mide la superposición entre predicciones y anotaciones reales, y F1@IoU0.25, donde una detección se considera correcta si IoU ≥ 0.25. Estas métricas permiten comparar el desempeño entre Llama-1B y Qwen-0.5B en la detección de objetos y elementos estructurales.

III. Metodología

La metodología propuesta se organiza como un pipeline que transforma un video convencional en una reconstrucción 3D semánticamente enriquecida. Cada etapa cumple una función específica: desde la generación de la nube de puntos mediante SLAM3R, pasando por su alineación geométrica, hasta la detección de objetos y superficies con SpatialLM y la posterior reconstrucción de elementos estructurales. Este flujo integrado permite obtener una representación tridimensional coherente y fácil de interpretar del entorno interior.



1. Entrada: Captura de Video
El proceso inicia con un video del interior del espacio. Este video proporciona las vistas necesarias para la reconstrucción 3D.
2. Reconstrucción 3D con SLAM3R
SLAM3R divide el video en fotogramas y procesa cada uno estimando la trayectoria de la cámara y generando una nube de puntos 3D.

Los mejores resultados de este modelo se obtuvieron ajustando algunos parámetros dentro en casos de memoria limitada. de la interfaz de Gradio que el repositorio de SLAM3R tiene implementado.
Salida: nube de puntos sin escala ni alineada en formato ply, pcd o glb.

3. Alineación y Normalización (resize.py con PCA)
Tomando como entrada la nube de puntos recién generada por SLAM3R, se centra, rota al eje Z, escala a la altura aproximada de una habitación y alinea el piso en Z=0, generando una nube compatible con SpatialLM.

Salida: resized.ply

4. SpatialLM – Detección de Objetos y Superficies
SpatialLM analiza la nube alineada, genera un prompt textual y utiliza un LLM para detectar objetos, paredes, puertas y ventanas.

Salida: detections.txt

5. Reconstrucción de Paredes (walls_to_surface.py)
A partir de las detecciones de tipo Wall que se encuentren en detections.txt, se reconstruyen y fusionan paneles 3D, generando una malla arquitectónica.
Salida: colored_output.obj

6. Visualización Final (viz_total.py)

Se visualiza la nube con detecciones y las superficies estructurales reconstruidas.

7. Cálculo de Métricas

Se comparan las predicciones contra valores reales (si existen) para obtener F1@IoU0.25 Pero el etiquetamiento sobre nube de puntos 3d es muy complejo y debe ser muy preciso.

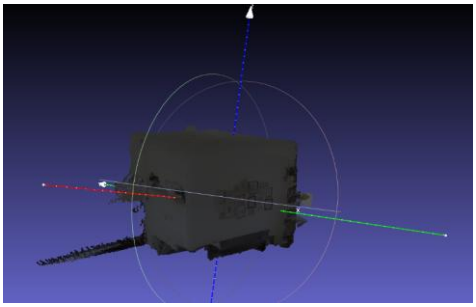
IV. Resultados

Usando una GPU RTX 3050 con 4 GB de VRAM, en esta sección se presentan los resultados obtenidos en cada etapa: la nube de puntos generada por SLAM3R, su alineación mediante PCA, las detecciones producidas por SpatialLM y la reconstrucción de paredes a partir del archivo de predicciones. Finalmente, se incluyen las métricas de referencia reportadas por los autores de SpatialLM para contextualizar el desempeño esperado del modelo.

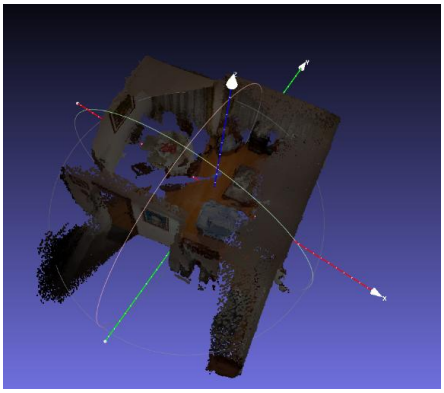
1. Video de entrada:



2. Reconstrucción 3D con SLAM3R:

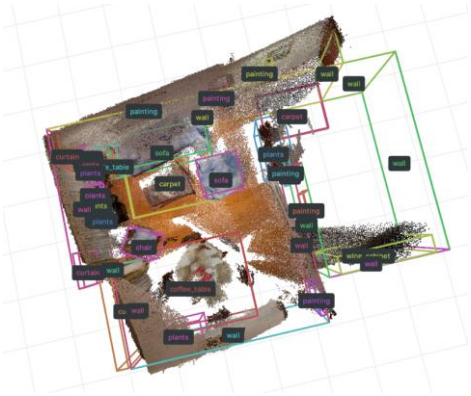


3. Alineación y Normalización (resize.py con PCA)

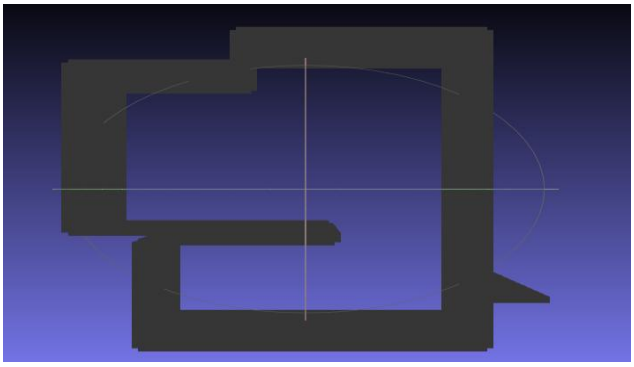


4. SpatialLM – Detección de Objetos y Superficies



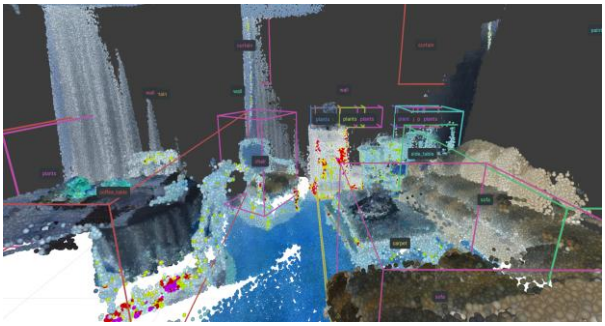


5. Reconstrucción de Paredes (walls_to_surface.py)



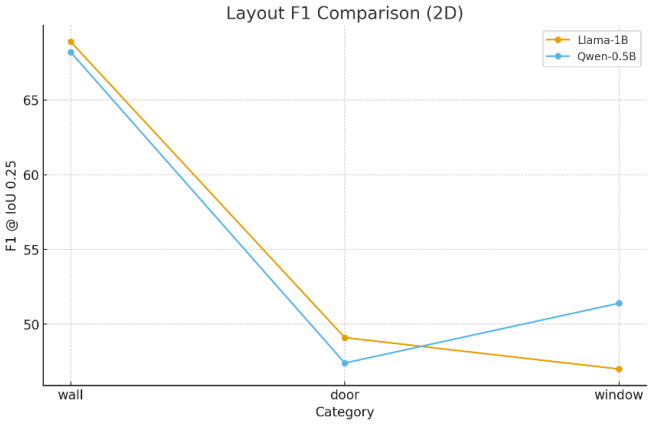
6. Visualización Final (viz_total.py)



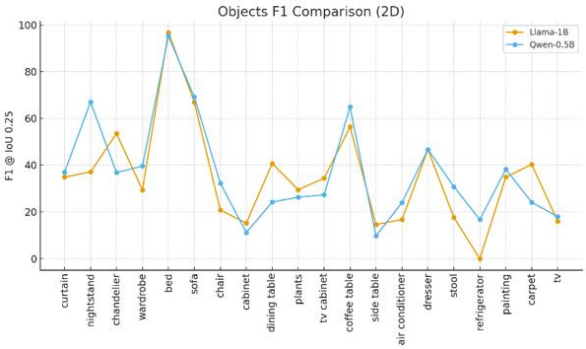


7. Métricas (F1@IoU0.25)

Aunque no se logró realizar el etiquetado manual de la nube de puntos generada para calcular métricas propias del pipeline implementado, se presentan a continuación los resultados oficiales del modelo SpatialLM reportados por sus autores, obtenidos sobre el conjunto de validación de la base de datos con el que fue entrenado. Estas métricas permiten entender el rendimiento esperado del modelo y sirven como referencia sobre qué tan bien es capaz de detectar objetos y elementos estructurales una vez recibe una nube de puntos correctamente alineada y normalizada.



En el caso del layout (paredes, puertas y ventanas), ambos modelos Llama-1B y Qwen-0.5B presentan un desempeño muy similar, con valores F1@IoU0.25 alrededor del 68% para paredes, lo cual demuestra una alta consistencia en la identificación de superficies grandes y claramente definidas. Las puertas y ventanas muestran valores moderados, aunque Qwen-0.5B evidencia una ligera ventaja en la detección de ventanas, lo que sugiere una mayor sensibilidad a elementos más delgados o con menor superficie.



En cuanto a la detección de objetos en 3D, los resultados muestran diferencias más marcadas entre ambos modelos. Llama-1B obtiene mejor desempeño en objetos grandes y volumétricos como camas, sofás y mesas de centro, lo que indica mayor estabilidad en categorías con estructuras geométricas amplias y bien definidas. Por otro lado, Qwen-0.5B destaca en la detección de objetos pequeños o con formas más complejas, como sillas, taburetes, pinturas y unidades de aire acondicionado, lo que refleja una mayor sensibilidad a detalles locales dentro de la nube de puntos. En conjunto, los resultados muestran que ninguno de los dos modelos es uniformemente superior, sino que cada uno presenta ventajas particulares dependiendo del tipo de objeto y su escala dentro de la escena.

CONCLUSIONES

El pipeline desarrollado demuestra que es posible obtener una reconstrucción 3D completa y semánticamente enriquecida de un entorno interior a partir de un video convencional. La combinación de SLAM3R para reconstrucción, un módulo de alineación PCA obligatorio para normalización espacial, y SpatialLM para detección semántica permite transformar una simple secuencia de imágenes en una representación tridimensional organizada, interpretable y útil para análisis estructural y visualización. La reconstrucción de superficies mediante el módulo walls_to_surface.py aporta además una aproximación clara a la lectura de planos, lo cual incrementa el valor práctico del sistema.

Un aspecto especialmente destacable es que la detección de objetos y superficies lograda por SpatialLM se obtuvo sin realizar ningún proceso de *fine-tuning* sobre las nubes generadas por este proyecto. Aun sin ajuste específico, el modelo logró identificar con precisión paredes, aperturas y múltiples categorías de objetos, mostrando un rendimiento sorprendentemente robusto para una arquitectura que originalmente no fue entrenada con estos datos. Esto evidencia el potencial de los modelos de lenguaje multimodales para generalizar hacia entornos reales incluso en condiciones distintas a las del conjunto de entrenamiento.

Finalmente, la comparación entre los dos modelos utilizados Llama-1B y Qwen-0.5B mostró que cada uno presenta fortalezas particulares: Llama-1B sobresale en objetos grandes y volumétricos, mientras que Qwen-0.5B destaca en elementos pequeños o de geometría compleja. Esta complementariedad sugiere que futuras versiones del pipeline podrían beneficiarse de estrategias híbridas o de ensamble. En conjunto, el método propuesto constituye una solución accesible, eficiente y sorprendentemente poderosa para reconstrucción y detección en interiores sin

necesidad de hardware especializado ni entrenamiento adicional.

Enlace a presentación:
https://www.canva.com/design/DAG5ZciTtM4/P0mjYXu9eZGRtm89qAWvcA/edit?utm_content=DAG5ZciTtM4&utm_campaign=designshare&utm_medium=link2&utm_source=sharebutton

BIBLIOGRAFÍA

[1] [1] J. Engel, T. Schöps, and D. Cremers, "LSD-SLAM: Large-Scale Direct Monocular SLAM," ECCV, pp. 834–849, 2014.

[2]

[3] [2] R. A. Newcombe et al., "KinectFusion: Real-time dense surface mapping and tracking," IEEE ISMAR, pp. 127–136, 2011.

[4]

[5] [3] S. Leutenegger, S. Lynen, M. Bosse, R. Siegwart, and P. Furgale, "Keyframe-based visual-inertial odometry using nonlinear optimization," IJRR, vol. 34, no. 3, pp. 314–334, 2015.

[6]

[7] [4] H. Fan et al., "SpatialLM: A Spatial Language Model for 3D Point Clouds," GitHub Repository, 2024. Disponible en: https://github.com/3dlg-hcvc/SpatialLM

[8]

[9] [5] PKU-VCL-3DV, "SLAM3R: Real-time Neural Scene Reconstruction," GitHub Repository, 2024. Disponible en: https://github.com/PKU-VCL-3DV/SLAM3R

[10]

[11] [6] M. Abadi et al., "TensorFlow: Large-Scale Machine Learning on Heterogeneous Systems," 2016. Disponible: https://www.tensorflow.org/

[12]

[13] [7] Q. Zhou, J. Park, and V. Koltun, "Open3D: A modern library for 3D data processing," arXiv, 2018.

[14]

[15] [8] K. Pearson, "On Lines and Planes of Closest Fit to Systems of Points in Space," Philosophical Magazine, vol. 2, no. 11, pp. 559-572, 1901. (Base teórica del PCA)

[16]

[17] [9] Rerun.io, "Rerun SDK: Visual analytics for multimodal data," Documentación. Disponible: https://www.rerun.io/

[18]

[19] [10] D. Cremers et al., "Photometric Bundle Adjustment for 3D Reconstruction," IEEE CVPR, pp. 1425–1434, 2015.

[20]

[21] [11] Y. Furukawa and C. Hernández, "Multi-view Stereo: A tutorial," Foundations and Trends in Computer Graphics and Vision, vol. 9, no. 1-2, pp. 1–148, 2015.

[22]

[12] M. Pollefeys et al., "Visual Modeling with a Hand-Held Camera," IJCV, vol. 59, no. 3, pp. 207–232, 2004. (Base de reconstrucción 3D desde video)